

- ❖ FixMatch: Simplifying Semi-Supervised Learning with Consistency and Confidence (2020)
  - Google research에서 연구된 논문이며, 2022년 12월 20일 기준으로 1430회 인용됨

---

## FixMatch: Simplifying Semi-Supervised Learning with Consistency and Confidence

---

Kihyuk Sohn\* David Berthelot\* Chun-Liang Li Zizhao Zhang Nicholas Carlini  
Ekin D. Cubuk Alex Kurakin Han Zhang Colin Raffel  
Google Research  
{kihyuks,dberth,chunliang,zizhaoz,ncarlini,  
cubuk,kurakin,zhanghan,crappel}@google.com

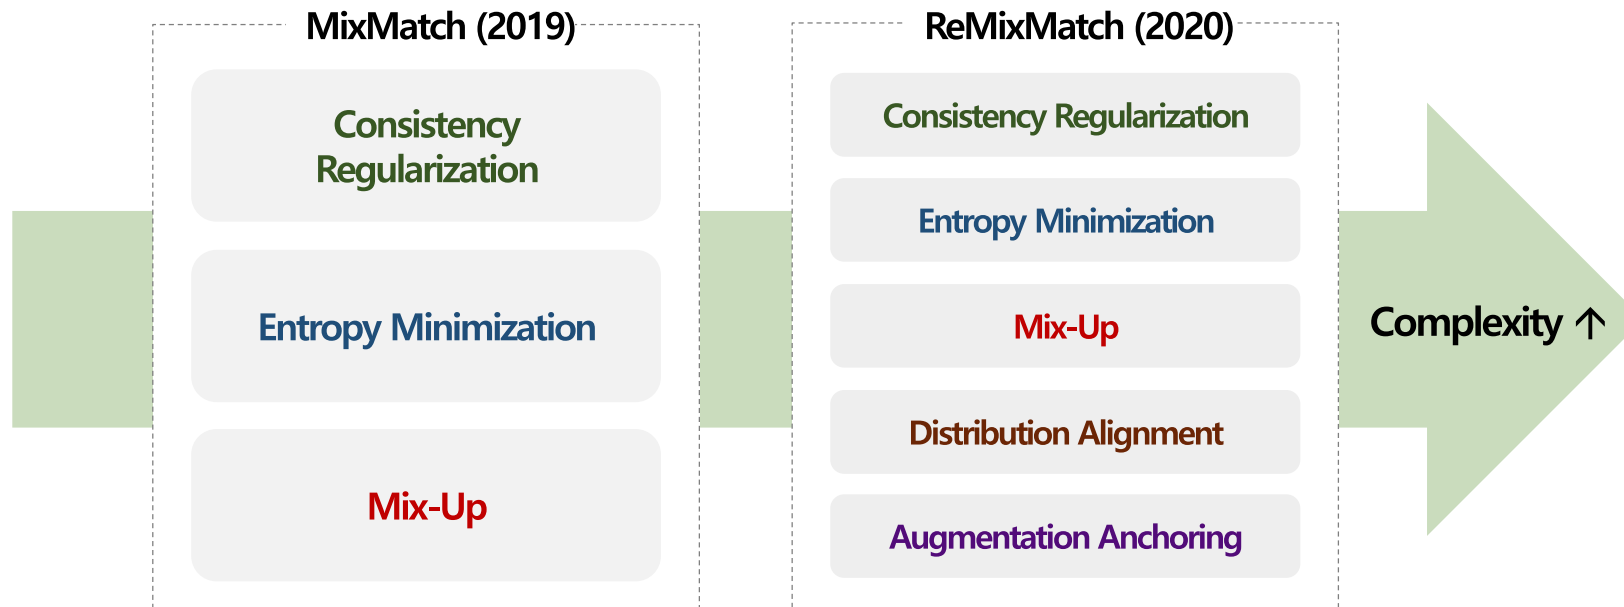
### Abstract

Semi-supervised learning (SSL) provides an effective means of leveraging unlabeled data to improve a model's performance. This domain has seen fast progress recently, at the cost of requiring more complex methods. In this paper we propose FixMatch, an algorithm that is a significant simplification of existing SSL methods. FixMatch first generates pseudo-labels using the model's predictions on weakly-augmented unlabeled images. For a given image, the pseudo-label is only retained if the model produces a high-confidence prediction. The model is then trained to predict the pseudo-label when fed a strongly-augmented version of the same image. Despite its simplicity, we show that FixMatch achieves state-of-the-art performance across a variety of standard semi-supervised learning benchmarks, including 94.93% accuracy on CIFAR-10 with 250 labels and 88.61% accuracy with 40 – just 4 labels per class. We carry out an extensive ablation study to tease apart the experimental factors that are most important to FixMatch's success. The code is available at <https://github.com/google-research/fixmatch>.

# FixMatch

## ❖ FixMatch: Simplifying Semi-Supervised Learning with Consistency and Confidence

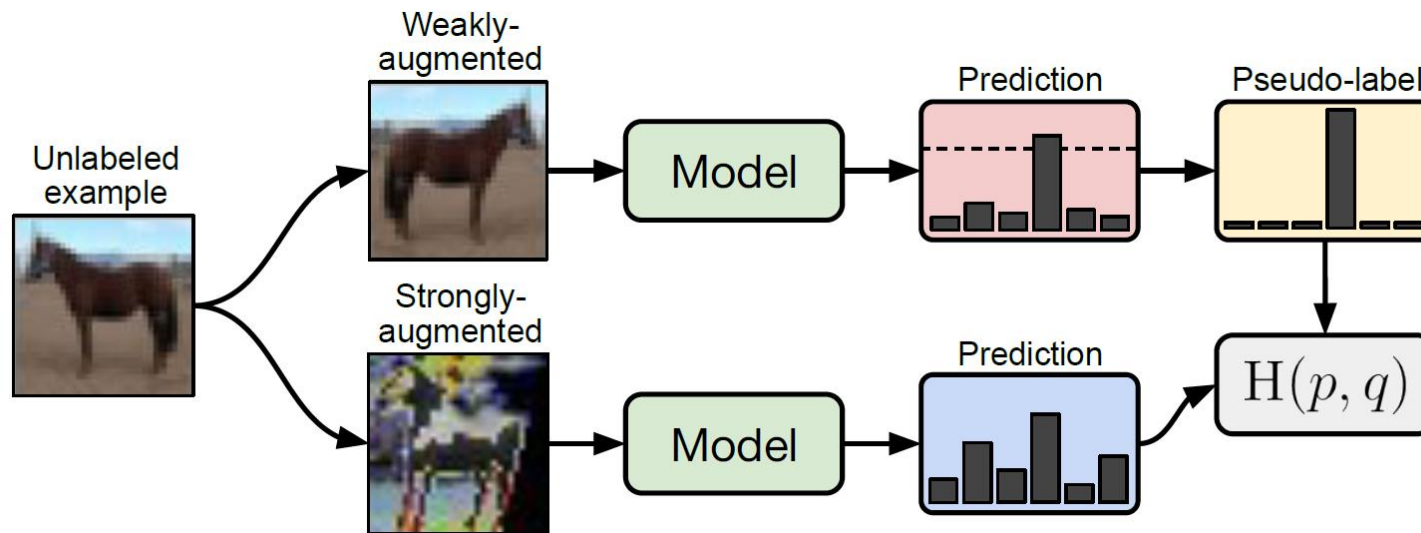
- 기존 방법론(MixMatch, ReMixMatch)은 성능 고도화를 위해 주요 기법들을 추가 및 혼합하는 방향으로 발전함
- 지나치게 정교한 loss term과 조정하기 어려운 수많은 사용자 정의 파라미터를 사용하는 형태임 → 복잡성이 높아짐



# FixMatch

## ❖ FixMatch: Simplifying Semi-Supervised Learning with Consistency and Confidence

- FixMatch는 MixMatch와 ReMixMatch의 복잡한 메커니즘 대신 Consistency Regularization과 Pseudo labeling 두 기법만을 결합한 간단한 구조를 구성함
  - ✓ 기존에 사용한 방법론 대비 가장 우수한 성능을 보임



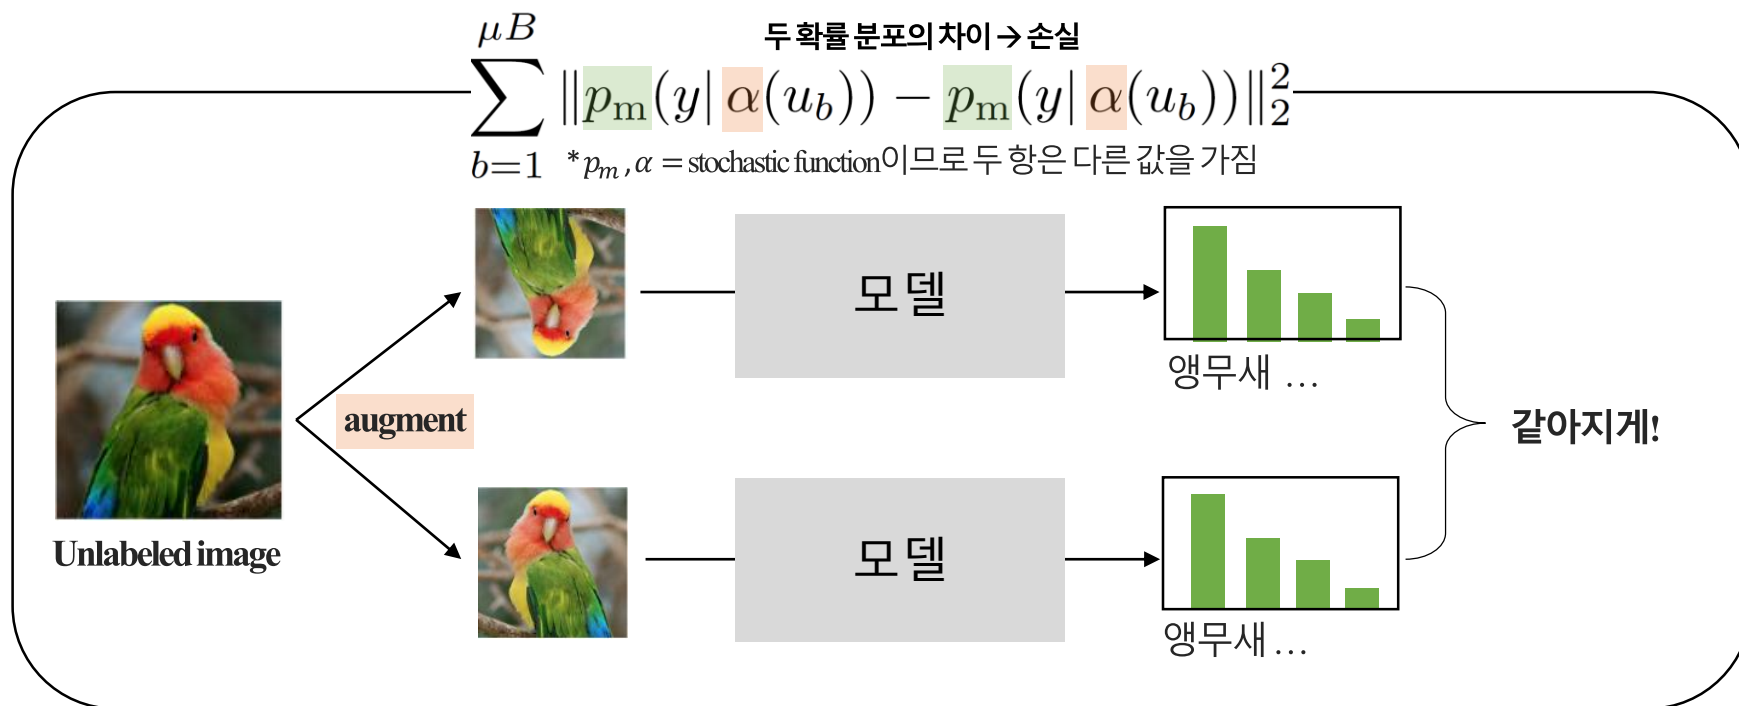
Consistency  
Regularization

Pseudo Labeling

# FixMatch

## ❖ FixMatch – Consistency regularization

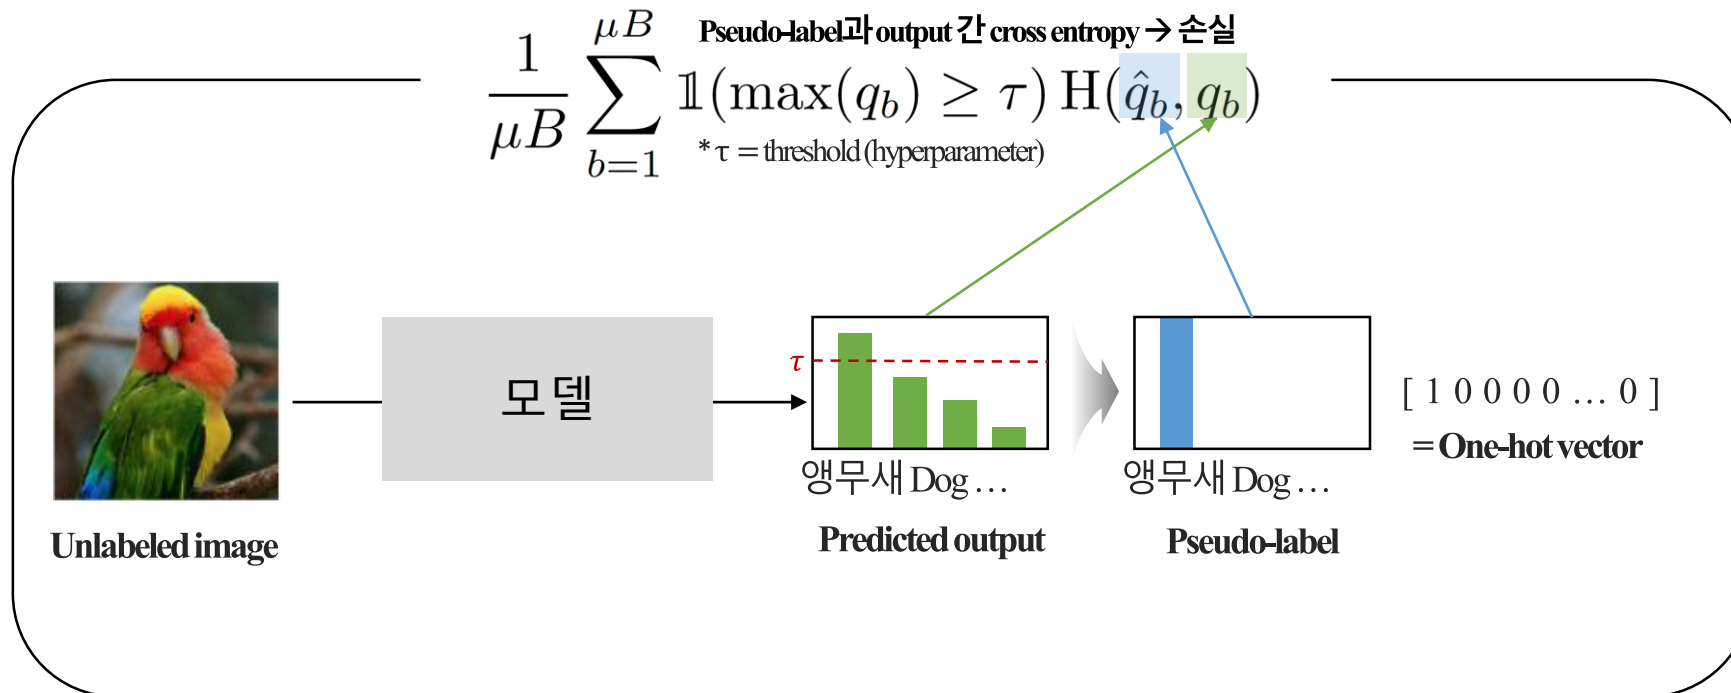
- 이미지에 가해진 약간의 변형에도 불구하고 레이블 값은 변하지 않는 것을 이용!
- 즉, 앵무새 이미지에 데이터 증강 기법을 적용하더라도 ‘앵무새’라는 레이블은 변하지 않음
- 먼저, 레이블이 있는 데이터를 사용해 모델을 학습시키고, 레이블이 없는 데이터에 서로 다른 데이터 증강 기법을 적용한 두 데이터를 학습된 모델에 입력해 나온 분포가 동일하게 만들도록 학습



# FixMatch

## ❖ FixMatch – Pseudo labeling

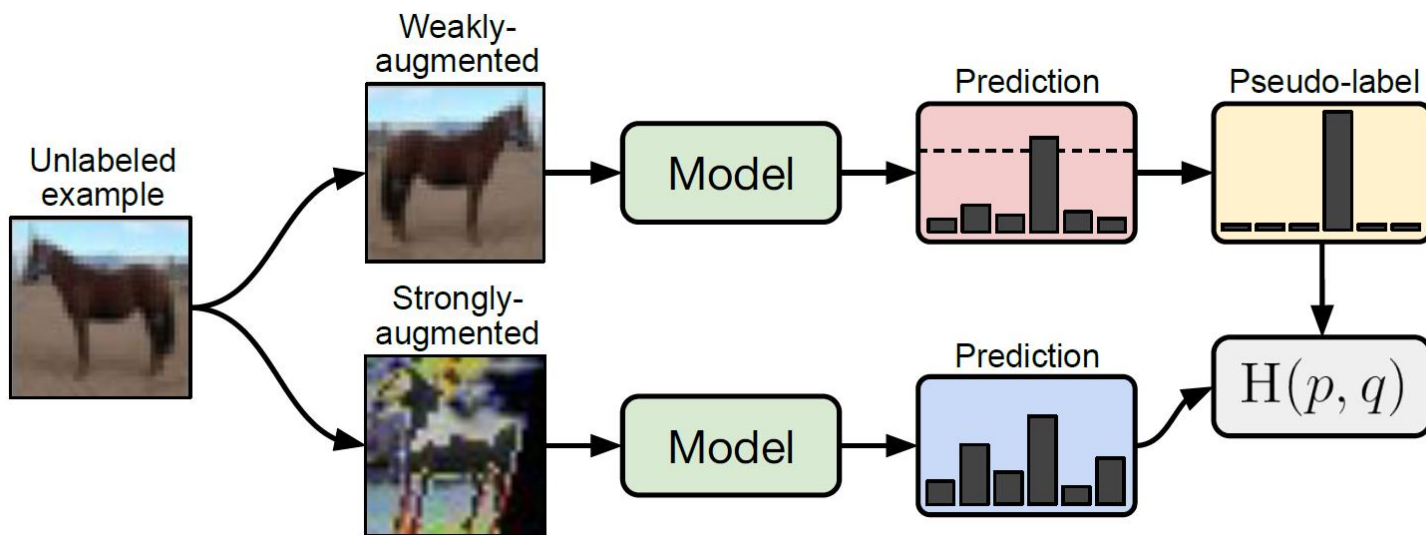
- 레이블 된 데이터를 통해 학습된 모델에, 레이블이 없는 데이터를 입력하여 예측된 레이블 값을 예측
- 예측 값들 중 가장 높은 확률에 해당하는 값으로 새로운 레이블 부여함 → Pseudo-labeled data
  - ✓ 여러 확률 값 중, 설정한 임계값을 넘을 경우에만 가짜 레이블로 사용
- 가짜 레이블과 실제 레이블을 가지고 모델을 최종 학습!



# FixMatch

## ❖ FixMatch

- 먼저, 레이블이 있는 데이터에 weak augmentation 적용 후, 모델 학습
- 그리고 레이블이 없는 데이터에 weak augmentation을 적용하고 모델에서 얻은 예측 값을 기반으로 pseudo label 생성 (entropy minimization과 동일한 효과)
- 마지막으로 동일한 레이블이 없는 데이터에 strong augmentation 적용 후, 모델에 통과시켜 얻어낸 예측 값과 가짜 레이블이 비슷해지도록 학습



Consistency  
Regularization

Pseudo Labeling

# FixMatch

## ❖ 손실 함수

- 지도 학습 손실 함수 (레이블이 있는 데이터 사용)

$$\ell_s = \frac{1}{B} \sum_{b=1}^B H(p_b, p_m(y \mid \alpha(x_b)))$$

✓  $p_b$  : label (one-hot vector)  
✓  $p_m$  : weakly augmented data의 prediction probability

- 비지도 학습 손실 함수 (레이블이 없는 데이터 사용)

$$\ell_u = \frac{1}{\mu B} \sum_{b=1}^{\mu B} \mathbb{1}(\max(q_b) \geq \tau) H(\hat{q}_b, p_m(y \mid \mathcal{A}(u_b)))$$

✓  $q_b$  : weakly augmented data의 prediction probability /  $\hat{q}_b$  : pseudo-label (one-hot vector)

✓  $p_m$  : strongly augmented data의 prediction probability

- 전제 손실 함수

$$\ell_s + \lambda_u \ell_u$$

✓ 람다는 비지도 학습 손실 함수의 영향력을 결정하는 값으로, FixMatch에서는 Pseudo label에서의 threshold 덕분에 따로 조절할 필요 없음